



Escola Politécnica
Estatística e análise de dados
Turma: 218040
SPRINT 1

30/08/2026

Grupo 3:

Leonardo Rogério de Alcantara Costa - RA: 25004184

Nicholas Coutinho Ganzarolli - RA: 26029362

Giovanni Nicolas Tapia Rodriguez - RA: 25019982

Miguel Afonso Barbieri - RA: 25003070

Arthur Henrique Silva Gerotto - RA:25007697

Docente: Alexandre Monteiro da Silva

Sumário

Sumário.....	1
1. Definição do problema.....	1
1.1 Contextualização.....	1
1.2 Problematização.....	2
1.3 Objetivo.....	2
1.4 Tamanho da amostra.....	2
1.5 Variáveis consideradas, justificativa e classificação.....	2
2. Variável qualitativa: Bairro.....	3
2.1 Tabela de distribuição de frequências.....	3
2.2 Representação gráfica.....	4
2.3 Medida resumo e interpretação.....	4
3. Variável quantitativa 1: Preço de venda.....	5
3.1 Tabela de distribuição de frequências.....	5
3.2 Representação gráfica.....	5
3.3 Medidas resumo e interpretação.....	6
4. Variável quantitativa 2: Área do lote.....	7
4.1 Tabela de distribuição de frequências.....	7
4.2 Identificação e tratamento de outliers.....	8
4.3 Tabela de frequências após a retirada dos outliers.....	9
4.4 Medidas resumo e interpretação.....	10
5. Diferença de preço entre bairros.....	11
6. Conclusão e Diretrizes Estratégicas.....	12
6.1. Resposta ao Problema de Negócio.....	12
6.2. Recomendações Práticas para a Imobiliária (Diretrizes para Corretores).....	12
6.3. Limitações da Sprint 1 e Próximos Passos.....	13
6.4 Anexo de Links e arquivos Notebooks do Python.....	13
7.Referências Bibliográficas.....	14

1. Definição do problema

1.1 Contextualização

A imobiliária atua na intermediação de compra e venda de imóveis residenciais. Atualmente, a precificação dos imóveis captados depende principalmente da experiência individual de cada corretor, o que gera avaliações inconsistentes: imóveis semelhantes recebem valores diferentes conforme quem os avalia, e não existe um parâmetro objetivo para orientar o vendedor sobre um preço justo de anúncio. Essa falta de critério compromete tanto a captação de novos imóveis quanto a credibilidade da empresa junto aos clientes.

1.2 Problematização

Quais fatores explicam a variação de preço entre os imóveis da nossa carteira, e é possível estabelecer parâmetros objetivos de precificação a partir deles?

1.3 Objetivo

Caracterizar o perfil dos imóveis da base quanto a preço, área do terreno e localização, identificando o valor típico de mercado e verificando se existe dependência entre a área do lote e o preço de venda.

1.4 Tamanho da amostra

A base é composta por **2.930 imóveis**, referentes a vendas realizadas entre 2006 e 2010, distribuídos em 28 bairros distintos.

1.5 Variáveis consideradas, justificativa e classificação

Preço de venda — quantitativa contínua. É a variável central do problema, já que o objetivo final é orientar a precificação dos imóveis captados.

Área do lote — quantitativa contínua. Escolhida porque o tamanho do terreno é um dos atributos físicos mais citados durante a negociação, sendo geralmente uma das peças centrais para a aquisição de um lote.

Bairro — qualitativa nominal. Permite segmentar a carteira geograficamente e verificar se a localização diferencia os preços praticados, informação essencial para orientar tanto a captação quanto a avaliação de imóveis.

Relação investigada: Espera-se que imóveis com lotes maiores apresentem preços mais altos.

2. Variável qualitativa: Bairro

2.1 Tabela de distribuição de frequências

A tabela apresenta a frequência absoluta, a frequência relativa e suas respectivas frequências acumuladas para cada um dos 28 bairros listados. A coluna "% área total" indica quanto cada bairro representa a soma das áreas de todos os lotes da base de dados.

Bairro	Frequência	Freq. Rel. (%)	Freq. Acum.	Freq. Rel. Acum. (%)	% área total
NAmes	443	15,12	443	15,12	14,96
CollgCr	267	9,11	710	24,23	8,98
OldTown	239	8,16	949	32,39	6,62
Edwards	194	6,62	1.143	39,01	6,76
Somerst	182	6,21	1.325	45,22	4,66
NridgHt	166	5,67	1.491	50,89	6,26
Gilbert	165	5,63	1.656	56,52	6,29
Sawyer	151	5,15	1.807	61,67	5,27
NWAmes	131	4,47	1.938	66,14	5,14
SawyerW	125	4,27	2.063	70,41	4,27
Mitchel	114	3,89	2.177	74,30	4,61
BrkSide	108	3,69	2.285	77,99	2,53
Crawfor	103	3,52	2.388	81,51	4,04
IDOTRR	93	3,17	2.481	84,68	2,76
Timber	72	2,46	2.553	87,14	4,42
NoRidge	71	2,42	2.624	89,56	3,10
StoneBr	51	1,74	2.675	91,30	1,95
SWISU	48	1,64	2.723	92,94	1,23
ClearCr	44	1,50	2.767	94,44	3,68
MeadowV	37	1,26	2.804	95,70	0,26
BrDale	30	1,02	2.834	96,72	0,19
Blmngtn	28	0,96	2.862	97,68	0,32
Veenker	24	0,82	2.886	98,50	1,25
NPKVill	23	0,78	2.909	99,28	0,21
Blueste	10	0,34	2.919	99,62	0,08
Greens	8	0,27	2.927	99,89	0,10
GrnHill	2	0,07	2.929	99,96	0,06
Landmrk	1	0,03	2.930	99,99	0,01

Tabela 1 — Distribuição de frequências por bairro

2.2 Representação gráfica




Gráfico 1 — Frequência absoluta de imóveis por bairro

2.3 Medida resumo e interpretação

A moda é **NAmes**, com 443 imóveis, o que representa 15,12% da amostra. Ou seja, aproximadamente 1 a cada 7 imóveis da base está localizado neste bairro. Como existem 28 localizações diferentes, essa concentração mostra que a oferta não é distribuída uniformemente: nos três bairros mais frequentes (NAmes, CollgCr e OldTown) concentram-se, sozinhos, 32,39% dos imóveis.

Uma hipótese possível seria a de que NAmes concentra mais imóveis por ter lotes menores e, portanto, maior adensamento. Os dados não sustentam essa leitura: o bairro responde por 15,12% dos imóveis e por 14,96% da área total de lotes — proporções praticamente idênticas. A maior quantidade de imóveis decorre, portanto, da maior extensão do bairro, e não de lotes menores que a média.

Implicação para a imobiliária: a captação deve priorizar os bairros de maior volume, mas a precificação não pode ser tratada de forma homogênea entre eles, como mostra o Gráfico 6 (preço médio por bairro).

3. Variável quantitativa 1: Preço de venda

3.1 Tabela de distribuição de frequências

Intervalo de preço (US\$)	Frequência absoluta	Freq. acumulada	Frequência %	Freq. % acumulada
(12046.788, 69882.154]	51	51	1,74	1,74
(69882.154, 126975.308]	600	651	20,48	22,22
(126975.308, 184068.462]	1.200	1.851	40,96	63,18
(184068.462, 241161.615]	578	2.429	19,73	82,91
(241161.615, 298254.769]	261	2.690	8,91	91,82
(298254.769, 355347.923]	124	2.814	4,23	96,05
(355347.923, 412441.077]	64	2.878	2,18	98,23
(412441.077, 469534.231]	28	2.906	0,96	99,19
(469534.231, 526627.385]	9	2.915	0,31	99,50
(526627.385, 583720.538]	7	2.922	0,24	99,74
(583720.538, 640813.692]	6	2.928	0,20	99,94
(640813.692, 697906.846]	0	2.928	0,00	99,94
(697906.846, 755000.0]	2	2.930	0,07	100,00

Tabela 2 — Distribuição de frequências do preço de venda

3.2 Representação gráfica




Gráfico 2 — Histograma do preço de venda

3.3 Medidas resumo e interpretação

Medida	Valor (US\$)
Média	180.796,06
Moda	135.000
Mediana	160.000

Tabela 3 — Medidas de tendência central do preço de venda

A média é de US\$ 180.796,06, a mediana é de US\$ 160.000 e a moda é de US\$ 135.000. O fato de a **média ser maior que a mediana** indica uma distribuição assimétrica à direita: existem imóveis de valor muito elevado — o máximo da base é US\$ 755.000, contra um mínimo de US\$ 12.789 — que puxam a média para cima, enquanto metade dos imóveis custa até US\$ 160.000. Esse comportamento é confirmado visualmente pelo Gráfico 3, com a cauda alongada à direita.

Implicação para a imobiliária: a mediana representa melhor o preço típico do mercado do que a média. Anunciar imóveis tomando a média como referência tenderia a superestimar o valor da maior parte da carteira. A moda de US\$ 135.000 indica ainda a existência de uma faixa de preço de maior liquidez.

4. Variável quantitativa 2: Área do lote

4.1 Tabela de distribuição de frequências

Intervalo de área	Frequência absoluta	Freq. acumulada	Frequência %	Freq. % acumulada
(1086.054, 17757.308]	2.804	2.804	95,70	95,70
(17757.308, 34214.615]	98	2.902	3,34	99,04
(34214.615, 50671.923]	16	2.918	0,55	99,59
(50671.923, 67129.231]	7	2.925	0,24	99,83
(67129.231, 83586.538]	1	2.926	0,03	99,86
(83586.538, 100043.846]	0	2.926	0,00	99,86
(100043.846, 116501.154]	1	2.927	0,03	99,89
(116501.154, 132958.462]	0	2.927	0,00	99,89
(132958.462, 149415.769]	0	2.927	0,00	99,89
(149415.769, 165873.077]	2	2.929	0,07	99,96
(165873.077, 182330.385]	0	2.929	0,00	99,96
(182330.385, 198787.692]	0	2.929	0,00	99,96
(198787.692, 215245.0]	1	2.930	0,03	99,99

Tabela 4 — Distribuição de frequências da área do lote

A tabela evidencia um problema: a primeira classe concentra praticamente toda a amostra, enquanto as demais ficam quase vazias. Isso ocorre porque alguns poucos lotes muito grandes alargam a amplitude e, conseqüentemente, os intervalos.




Gráfico 3 — Histograma da área do lote (dados brutos)

4.2 Identificação e tratamento de outliers

Para tratar essa distorção, os valores atípicos foram identificados pelo critério do intervalo interquartil (IIQ), que considera outlier todo valor fora do intervalo $[Q1 - 1,5 \times IIQ; Q3 + 1,5 \times IIQ]$.

Medida	Valores
Q1	7.440,25
Q3	11.555,25
IIQ	4.115,00
Limite inferior	1.267,75
Limite superior	17.727,75

Tabela 5 — Quartis e limites para detecção de outliers

Foram identificados **127 outliers**, o que corresponde a 4,33% da amostra. Como o menor lote da base mede 1.300 e o limite inferior é 1.267,75, nenhum imóvel foi excluído pela extremidade inferior. Todos os outliers estão acima do limite superior de 17.727,75. O maior lote da base chega a 215.245, mais de 20 vezes a mediana.

4.3 Tabela de frequências após a retirada dos outliers

Intervalo de área	Frequência absoluta	Freq. acumulada	Frequência %	Freq. % acumulada
(1283.628, 2559.308]	105	105	3,75	3,75
(2559.308, 3818.615]	89	194	3,18	6,93
(3818.615, 5077.923]	125	319	4,46	11,39
(5077.923, 6337.231]	183	502	6,53	17,92
(6337.231, 7596.538]	279	781	9,95	27,87
(7596.538, 8855.846]	461	1.242	16,45	44,32
(8855.846, 10115.154]	496	1.738	17,70	62,02
(10115.154, 11374.462]	421	2.159	15,02	77,04
(11374.462, 12633.769]	264	2.423	9,42	86,46
(12633.769, 13893.077]	175	2.598	6,24	92,70
(13893.077, 15152.385]	90	2.688	3,21	95,91
(15152.385, 16411.692]	70	2.758	2,50	98,41
(16411.692, 17671.0]	45	2.803	1,61	100,02

Tabela 6 — Distribuição de frequências da área do lote (sem outliers)

Com os outliers removidos, os intervalos passam a distribuir a amostra de forma muito mais informativa, revelando a real concentração dos lotes em torno de 8.000 a 11.000.




Gráfico 4 — Histograma da área do lote sem outliers

4.4 Medidas resumo e interpretação

Medida	Valor
Média	10.147,92
Moda	9.600
Mediana	9.436,50

Tabela 7 — Medidas de tendência central da área do lote

A média é de 10.147,92, a mediana de 9.436,50 e a moda de 9.600. Assim como no preço de venda, a média supera a mediana, confirmando a assimetria à direita já observada no histograma. A proximidade entre moda e mediana reforça que o lote típico do mercado gira em torno de 9.436,50.

Implicação para a imobiliária: o terreno padrão da carteira é bastante homogêneo. Os lotes muito grandes constituem um segmento à parte, com lógica de precificação própria, e não devem ser avaliados pelos mesmos parâmetros do restante.

5. Diferença de preço entre bairros




Gráfico 6 — Preço médio do imóvel por bairro

O gráfico confirma que a localização diferencia fortemente os preços praticados. Como o bairro é uma variável qualitativa nominal, não é possível calcular a correlação com o preço; a comparação é feita por meio da média de cada grupo. A amplitude entre o bairro mais caro e o mais barato mostra que a localização é um fator de precificação tão ou mais relevante que a área do terreno.

6. Conclusão e Diretrizes Estratégicas

A partir da análise dos 2.930 imóveis da base, foi possível atender o objetivo central deste estudo, e findar uma resposta à problematização inicial, estabelecendo critérios objetivos para superar a subjetividade na avaliação dos corretores.

6.1. Resposta ao Problema de Negócio

Os dados demonstram que nem a localização nem a área do lote explicam, isoladamente, a variação total dos preços. No entanto, a combinação dessas duas variáveis estabelece a base necessária para a precificação:

- Parâmetro de Referência do Mercado: A mediana de US\$ 160.000 (e não a média de US\$ 180.796,06) deve ser adotada como o indicador central do preço típico da carteira. A assimetria positiva indica que a média infla artificialmente a expectativa de valor de 50% dos imóveis da base.
- Segmentação por Tamanho de Terreno: O padrão de lote residencial varia tipicamente entre 7.440 m² e 11.555 m² (mediana de 9.436 m²). Os 127 imóveis (4,33%) identificados como outliers de área pertencem a um nicho específico (chácaras/grandes lotes) e não devem ser precificados sob a mesma regra dos lotes padrão.
- Peso da Localização: A localização geográfica é um fator determinante de disparidade de preços. Bairros como NoRidge e StoneBr apresentam médias superiores a US\$ 300.000, enquanto MeadowV e IDOTRR possuem médias próximas a US\$ 100.000, mostrando que o "efeito bairro" pode triplicar o valor praticado por metro quadrado.

6.2. Recomendações Práticas para a Imobiliária (Diretrizes para Corretores)

1. Matriz de Precificação Inicial: Desenvolver uma tabela de referência cruzando o Bairro (localização) com a Área do Lote (ajustada pela mediana local), para criar uma faixa de valor de anúncio (mínimo, médio/mediano e máximo esperado).
2. Protocolo para Imóveis Atípicos: Criar um fluxo de avaliação diferenciado (com perícia técnica dedicada) para imóveis com lotes superiores a 17.727 m², evitando que esses dados distorçam a precificação do portfólio comum.

3. Foco Operacional na Captação: Concentrar os esforços de captação em bairros de alta representatividade e liquidez (como NAmes, CollgCr e Old Town, que somam 32,39% da carteira), mas aplicando a precificação regionalizada para cada um.

6.3. Limitações da Sprint 1 e Próximos Passos

Como demonstrado no gráfico de dispersão, existe uma variação residual substancial nos preços que a área do terreno não consegue explicar sozinha. Portanto, para as próximas Sprints, recomenda-se:

- Amplificar a análise das variáveis, tanto qualitativas como quantitativas na amostra, para determinar se alguma afeta o preço do imóvel.
- Incluir no estudo, variáveis qualitativas de estado de conservação/acabamento e variáveis quantitativas, como área construída total e ano de construção.
- Evoluir da análise bidimensional para um modelo de Regressão Múltipla, permitindo estimar o impacto isolado de cada atributo no preço final de venda.

6.4 Anexo de Links e arquivos Notebooks do Python

Arquivo = PROJ1 - QUALITATIVO (BAIRRO)

https://colab.research.google.com/drive/1m_tNOhU4JEvLfdpko5nenig020zCWVC9?usp=sharing

Arquivo = PROJ1 - QUANTITATIVO (PREÇO)

<https://colab.research.google.com/drive/1MHUSNcdTqonpHn0yPhRyX2AIDbFfDFoa?usp=sharing>

Arquivo = PROJ1 - QUANTITATIVO 2 (IMÓVEIS)

https://colab.research.google.com/drive/1JaEV9SAIwswWKv64B_2fSqN5QZ1q1lna?usp=sharing

Além dos links que estão presentes acima, estará disponível o acesso ao arquivo “.ipynb” e aos “Dados Habitacionais de Ames.xlsx” anexado diretamente na tarefa “Sprint1” na plataforma Canvas dos mesmos 3 Notebooks do Python e planilha Excel.

7.Referências Bibliográficas

MONTEIRO, Alexandre *et al.* **2.Tabelas e Gráficos**. Campinas: PUC-Campinas, 2026. Material de apoio para a disciplina Estatística e Análise de Dados, disponibilizado no ambiente virtual Canvas. Disponível em: <https://puc-campinas.instructure.com>. Acesso em: 11 ago. 2026.

MONTEIRO, Alexandre *et al.* **2-Python - Distribuições de frequência**. Campinas: PUC-Campinas, 2026. Material de apoio para a disciplina Estatística e Análise de Dados, disponibilizado no ambiente virtual Canvas. Disponível em: <https://puc-campinas.instructure.com>. Acesso em: 11 ago. 2026.

MONTEIRO, Alexandre *et al.* **3-Python - Gráficos e Medidas**. Campinas: PUC-Campinas, 2026. Material de apoio para a disciplina Estatística e Análise de Dados, disponibilizado no ambiente virtual Canvas. Disponível em: <https://puc-campinas.instructure.com>. Acesso em: 17 ago. 2026.