



Escola Politécnica
Estatística e análise de dados
Turma: 218040
SPRINT 2

20/09/2026

Grupo 3:

Leonardo Rogério de Alcantara Costa - RA: 25004184

Nicholas Coutinho Ganzarolli - RA: 26029362

Giovanni Nicolas Tapia Rodriguez - RA: 25019982

Miguel Afonso Barbieri - RA: 25003070

Arthur Henrique Silva Gerotto - RA:25007697

Docente: Alexandre Monteiro da Silva

Sumário

Sumário.....	2
1. Introdução: retomada do contexto e das variáveis.....	3
1.1 Contextualização e problematização.....	3
1.2 Objetivo da Sprint 2.....	3
1.3 Tamanho da amostra.....	3
1.4 Variáveis consideradas e correções em relação à Sprint 1.....	3
1.5 Síntese dos resultados da Sprint 1.....	4
2. Variável quantitativa 1: Preço de venda (Sale Price).....	4
2.1 Separatrizes (Q1, Q2 e Q3).....	4
2.2 Boxplot e valores discrepantes.....	5
2.3 Interpretação da assimetria.....	7
3. Variável quantitativa 2: Área do lote.....	7
3.1 Separatrizes (Q1, Q2 e Q3).....	7
3.2 Boxplot e valores discrepantes.....	8
3.3 Interpretação da assimetria.....	10
4. Boxplot comparativo.....	10
5. Estudo da variabilidade dos dados.....	11
5.1 Desvio padrão.....	11
5.2 Coeficiente de variação.....	12
5.3 Comparação da homogeneidade.....	12
6. Conclusão e Diretrizes Estratégicas.....	13
6.1 Recomendações Práticas para a Imobiliária.....	13
6.2 Limitações da Sprint 2 e Próximos Passos.....	13
7. Referências Bibliográficas.....	14

1. Introdução: retomada do contexto e das variáveis

1.1 Contextualização e problematização

Esta Sprint dá continuidade ao estudo iniciado na Sprint 1 sobre a carteira de imóveis de uma imobiliária que atua na intermediação de compra e venda de imóveis residenciais. Conforme apresentado anteriormente, a precificação dos imóveis captados depende principalmente da experiência individual de cada corretor, o que gera avaliações inconsistentes: imóveis semelhantes recebem valores diferentes conforme quem os avalia, e não existe um parâmetro objetivo para orientar o vendedor sobre um preço justo de anúncio.

A problematização permanece a mesma: quais fatores explicam a variação de preço entre os imóveis da carteira, e é possível estabelecer parâmetros objetivos de precificação a partir deles?

1.2 Objetivo da Sprint 2

Aprofundar a caracterização das duas variáveis quantitativas escolhidas na Sprint 1 por meio das medidas separatrizes (quartis), dos boxplots e da identificação de valores discrepantes, e quantificar a variabilidade dos dados com o desvio padrão e o coeficiente de variação. Além disso, comparar o comportamento do preço de venda entre as diferentes categorias da variável qualitativa (bairro) por meio de um boxplot comparativo.

1.3 Tamanho da amostra

A base continua composta por 2.930 imóveis, referentes a vendas realizadas entre 2006 e 2010, distribuídos em 28 bairros distintos. Nesta Sprint, as medidas foram calculadas sobre a base completa ($n = 2.930$), sem a exclusão prévia de outliers, uma vez que a identificação desses valores é justamente um dos objetos de estudo.

1.4 Variáveis consideradas e correções em relação à Sprint 1

Preço de venda (SalePrice) — quantitativa contínua, medida em dólares americanos (US\$). É a variável central do problema, já que o objetivo final é orientar a precificação dos imóveis captados.

Área do lote (Lot Area) — quantitativa contínua, medida em pés quadrados (ft^2). Escolhida porque o tamanho do terreno é um dos atributos físicos mais citados durante a negociação.

Bairro (Neighborhood) — qualitativa nominal, com 28 categorias. Permite segmentar a carteira geograficamente e verificar se a localização diferencia os preços praticados.

Correção em relação à Sprint 1: na conclusão do relatório anterior, a área do lote foi apresentada em metros quadrados (m²). A base de dados de Ames registra essa variável em pés quadrados (ft²), unidade que passa a ser adotada em todas as análises deste relatório. Os valores numéricos apresentados na Sprint 1 (Q1 = 7.440,25; Q3 = 11.555,25; mediana = 9.436,50) permanecem corretos, apenas com a unidade retificada.

1.5 Síntese dos resultados da Sprint 1

A Sprint 1 mostrou que o preço de venda apresenta média de US\$ 180.796,06, mediana de US\$ 160.000 e moda de US\$ 135.000, configurando uma distribuição assimétrica à direita. A área do lote apresentou média de 10.147,92 ft², mediana de 9.436,50 ft² e moda de 9.600 ft², com 127 lotes identificados como outliers pelo critério do intervalo interquartil. O bairro NAmes concentra 15,12% dos imóveis, e o gráfico de preço médio por bairro evidenciou que a localização diferencia fortemente os preços praticados. As análises a seguir aprofundam esses resultados.

2. Variável quantitativa 1: Preço de venda (Sale Price)

2.1 Separatrizes (Q1, Q2 e Q3)

Os quartis dividem o conjunto ordenado de preços em quatro partes com a mesma quantidade de imóveis. Foram obtidos com a função `describe()` do pandas.

Medida	Valor (US\$)
Q1 (1º quartil – 25%)	129.500,00
Q2 (2º quartil – mediana – 50%)	160.000,00
Q3 (3º quartil – 75%)	213.500,00
Amplitude interquartil (AIQ = Q3 – Q1)	84.000,00

Tabela 1 — Separatrizes do preço de venda

```
df.SalePrice.describe().round(2)
```

Figura 1 — Cálculo das separatrizes do preço de venda no Python

Interpretação do Q1: 25% dos imóveis da carteira foram vendidos por até US\$129.500,00, ou seja, um em cada quatro imóveis custa no máximo esse valor. Os 75% restantes foram vendidos acima dele.

Interpretação do Q2 (mediana): metade dos imóveis foi vendida por até US\$160.000,00 e a outra metade acima desse valor. Esse é o preço típico do mercado, já destacado na Sprint 1 como referência mais adequada do que a média (US\$180.796,06).

Interpretação do Q3: 75% dos imóveis foram vendidos por até US\$213.500,00; apenas 25% da carteira ultrapassa esse valor, o que caracteriza o segmento de imóveis de padrão mais elevado.

A amplitude interquartil indica que os 50% centrais dos imóveis, aqueles que representam o mercado mais comum variam dentro de uma faixa de 84 mil dólares. Observa-se ainda que a distância entre Q1 e a mediana (US\$ 30.500) é bem menor do que a distância entre a mediana e Q3 (US\$ 53.500).

Implicação para a imobiliária: a faixa entre Q1 e Q3 pode ser adotada como a "faixa de referência" para anúncios de imóveis padrão. Um imóvel anunciado fora dessa faixa exige justificativa adicional (localização, área ou acabamento diferenciados).

2.2 Boxplot e valores discrepantes

O boxplot resume graficamente as separatrizes: a caixa vai de Q1 a Q3, a linha interna representa a mediana e as hastes se estendem até os limites inferior e superior. Os pontos além das hastes são os valores discrepantes (outliers), definidos pelo critério do intervalo interquartil como todo valor fora do intervalo $[Q1 - 1,5 \times AIQ \mid Q3 + 1,5 \times AIQ]$




Gráfico 1 — Boxplot do preço de venda (US\$), com outliers

Medida	Valor (US\$)
Limite inferior ($Q1 - 1,5 \times AIQ$)	3.500,00
Limite superior ($Q3 + 1,5 \times AIQ$)	339.500,00
Mínimo observado	12.789,00
Máximo observado	755.000,00

Tabela 2 — Limites para detecção de outliers do preço de venda

Como o menor preço da base é superior ao limite inferior, não há outliers inferiores: nenhum imóvel foi vendido por um valor atipicamente baixo em relação à distribuição geral. Já acima do limite superior foram identificados 137 imóveis, o que corresponde a 4,68% da amostra. Todos os valores discrepantes são, portanto, superiores. O imóvel mais caro da base custa mais de duas vezes o limite superior e cerca de 4,7 vezes a mediana.

```
df[df.SalePrice>lsup]
```

Figura 2 — Identificação dos outliers do preço de venda no Python




Gráfico 2 — Boxplot do preço de venda (US\$), sem outliers

Com os outliers ocultados (Gráfico 2), a caixa fica mais legível e é possível observar que a haste superior (de Q3 até o limite superior) é consideravelmente mais longa que a haste inferior (do limite inferior até Q1), reforçando a concentração de imóveis nos valores mais baixos e o alongamento da distribuição para a direita.

2.3 Interpretação da assimetria

Três evidências apontam, de forma convergente, para uma distribuição assimétrica à direita (assimetria positiva):

- **Posição da mediana na caixa:** a mediana está mais próxima de Q1 do que de Q3. A metade superior da caixa é maior que a inferior.
- **Comprimento das hastes:** a haste superior é muito mais longa que a inferior, e os 137 outliers estão todos concentrados à direita, formando uma cauda alongada até US\$755.000.
- **Média maior que a mediana:** a média de US\$180.796,06 supera a mediana de US\$160.000 em cerca de US\$20.800, confirmando que os valores extremos superiores puxam a média para cima.

Implicação para a imobiliária: a assimetria positiva confirma que a maior parte da carteira se concentra nas faixas de preço mais baixas e que existe um segmento reduzido de imóveis de alto padrão que se comporta de forma distinta. Esses 137 imóveis não devem ser precificados pelos mesmos parâmetros do restante da carteira.

3. Variável quantitativa 2: Área do lote

3.1 Separatrizes (Q1, Q2 e Q3)

As separatrizes da área do lote foram obtidas com a função `describe()` do pandas, conforme o notebook "PROJETO 2".

Medida	Valor (ft²)
Q1 (1º quartil – 25%)	7.440,25
Q2 (2º quartil – mediana – 50%)	9.436,50
Q3 (3º quartil – 75%)	11.555,25
Amplitude interquartil (AIQ = Q3 – Q1)	4.115,00

Tabela 3 — Separatrizes da área do lote

```
df1.describe().round(2)
```

Figura 3 — Medidas resumo da área do lote no Python

Interpretação do Q1: 25% dos lotes da carteira têm área de até 7.440,25 ft². São os terrenos menores.

Interpretação do Q2 (mediana): metade dos lotes tem até 9.436,50 ft² e a outra metade é maior que isso. Esse é o tamanho de terreno típico da carteira.

Interpretação do Q3: 75% dos lotes têm área de até 11.555,25 ft²; apenas um em cada quatro terrenos ultrapassa esse tamanho.

A amplitude interquartil mostra que os 50% centrais dos lotes variam dentro de uma faixa relativamente estreita. Diferentemente do preço, aqui a mediana está praticamente no centro da caixa: a distância de Q1 até a mediana e dela até Q3 possuem valores muito próximos.

Implicação para a imobiliária: o lote padrão da carteira é bastante homogêneo, girando em torno de 9.400 ft². Terrenos dentro da faixa de 7.440 a 11.555 ft² podem ser tratados como "lote padrão" na precificação.

3.2 Boxplot e valores discrepantes




Gráfico 3 — Boxplot da área do lote (ft²), com outliers

Medida	Valor (ft²)
Limite inferior ($Q1 - 1,5 \times AIQ$)	1.267,75
Limite superior ($Q3 + 1,5 \times AIQ$)	17.727,75
Mínimo observado	1.300,00
Máximo observado	215.245,00

Tabela 4 — Limites para detecção de outliers da área do lote

O menor lote da base está acima do limite inferior, logo não existem outliers inferiores. Acima do limite superior foram identificados 127 lotes, o que corresponde a 4,33% da amostra. O maior lote da base é mais de 12 vezes o limite superior e mais de 22 vezes a mediana, o que explica a escala comprimida do Gráfico 3, em que a caixa aparece "esmagada" junto à origem.

```
df[df1 > l_sup]
```

Figura 4 — Identificação dos outliers da área do lote no Python




Gráfico 4 — Boxplot da área do lote (ft²), sem outliers

Após a retirada dos outliers, restaram 2.803 lotes (Gráfico 4). Nesse recorte a caixa se torna claramente visível, com hastes de comprimento semelhante, e a distribuição dos lotes padrão se mostra próxima da simetria.

3.3 Interpretação da assimetria

- **Nos dados completos:** a distribuição é fortemente assimétrica à direita. Embora a caixa em si seja quase simétrica, os 127 outliers superiores formam uma cauda extremamente longa e a média supera a mediana.
- **Nos lotes padrão (sem outliers):** a distribuição é aproximadamente simétrica, com a mediana centralizada na caixa e hastes de tamanho semelhante, como se observa no Gráfico 4.

Em outras palavras, a assimetria da área do lote é causada quase exclusivamente por um pequeno grupo de terrenos muito grandes (chácaras e grandes glebas), e não por uma tendência geral da carteira.

Implicação para a imobiliária: os 127 lotes discrepantes constituem um nicho à parte, com lógica de precificação própria, e devem ser avaliados por perícia dedicada. Para os demais 2.803 imóveis, a área do terreno é um atributo previsível e pode ser usada como parâmetro direto de precificação.

4. Boxplot comparativo

Para avaliar como a localização influencia a precificação dos imóveis, foi construído o boxplot comparativo do **Preço de Venda (SalePrice)** segmentado pelas categorias da variável qualitativa **Bairro (Neighborhood)**.

- **Forte Disparidade de Preços Entre Bairros:** Observa-se uma variação significativa no preço mediano entre as diferentes localizações. Bairros nobres como *NoRidge*, *NridgHt* e *StoneBr* apresentam medianas de preço superiores a valor de US\$300.000,00, enquanto bairros mais populares como *MeadowV*, *IDOTRR* e *BrDale* possuem medianas abaixo de US\$100.000,00.
- **Variabilidade Intrabairro Distinta:** A amplitude interquartil (tamanho da caixa) varia consideravelmente dependendo da região. Bairros de alto padrão demonstram maior dispersão dos preços (caixas mais longas), indicando grande heterogeneidade nos imóveis locais. Já bairros de menor valor venal apresentam caixas comprimidas e hastes curtas, refletindo alto grau de padronização construtiva.

- **Concentração Assimétrica de Outliers:** A presença de valores discrepantes (pontos fora das hastes) ocorre predominantemente nas regiões de preço médio e alto (como *CollgCr*, *Crawfor* e *SawyerW*). Isso indica a presença de imóveis atípicos ou de altíssimo padrão situados em bairros predominantemente de padrão médio.




Gráfico 5 — Boxplot comparativo do preço de venda por bairro (US\$)

5. Estudo da variabilidade dos dados

As medidas de dispersão quantificam o quanto os dados se afastam do centro da distribuição. Foram calculados o desvio padrão (na mesma unidade da variável) e o coeficiente de variação (medida relativa, em %), que permite comparar a homogeneidade de variáveis medidas em unidades diferentes.

5.1 Desvio padrão

Variável	Média	Desvio padrão	Unidade
Preço de venda	180.796,06	79.886,69	US\$
Área do lote	10.147,92	7.880,02	ft ²

Tabela 6 — Média e desvio padrão das variáveis quantitativas ($n = 2.930$)

O desvio padrão: Em média, os preços dos imóveis se afastam cerca de 80 mil dólares da média. Na área do lote, as áreas se afastam em média cerca de 7.900 ft² da média. Como

as duas variáveis são medidas em unidades diferentes, o desvio padrão isoladamente não permite dizer qual delas é mais dispersa; para isso utiliza-se o coeficiente de variação.

5.2 Coeficiente de variação

O coeficiente de variação (CV) é a razão entre o desvio padrão e a média, expressa em porcentagem: $CV = (s / \bar{x}) \times 100$. Por ser adimensional, permite comparar a dispersão relativa de variáveis com unidades distintas.

Variável	Desvio padrão	Média	CV (%)
Preço de venda (US\$)	79.886,69	180.796,06	44,19
Área do lote (ft²)	7.880,02	10.147,92	77,65

Tabela 7 — Coeficiente de variação das variáveis quantitativas

```
scipy.stats.variation(df1, ddof = 1) * 100
```

Figura 6 — Cálculo do coeficiente de variação no Python

O coeficiente de variação da área do lote é de 77,65%, calculado no notebook com a função `variation` da biblioteca `scipy`. Isso significa que o desvio padrão corresponde a mais de três quartos da média, uma dispersão relativa muito alta, consequência direta dos 127 lotes discrepantes que alongam a distribuição.

O coeficiente de variação do preço de venda é de 44,19%. Nesse caso, o desvio padrão corresponde a pouco menos da metade da média.

5.3 Comparação da homogeneidade

Segundo a classificação usual do coeficiente de variação até 15% baixa dispersão (dados homogêneos), entre 15% e 30% média dispersão, e acima de 30% alta dispersão (dados heterogêneos), portanto ambas as variáveis são classificadas como heterogêneas. Entretanto, a área do lote é consideravelmente mais heterogênea do que o preço de venda: a dispersão relativa da área é cerca de 1,76 vez maior que a do preço.

Esse resultado pode parecer contraditório com a conclusão da seção 3, de que o lote padrão é homogêneo. A explicação está nos outliers: os 127 lotes muito grandes inflam o desvio padrão da área de forma desproporcional, enquanto os 137 outliers de preço, embora numerosos, são proporcionalmente menos extremos. Assim, o preço de venda é a variável mais homogênea das duas quando se considera a base completa.

Implicação para a imobiliária: a área do lote, tomada isoladamente na base completa, é um parâmetro instável para precificação por causa dos terrenos atípicos. O preço, apesar de também heterogêneo, é mais previsível. Na prática, a imobiliária deve separar os lotes discrepantes antes de usar a área como critério e trabalhar com faixas de preço por segmento, em vez de um único valor de referência.

6. Conclusão e Diretrizes Estratégicas

A partir das separatrizes, dos boxplots e das medidas de dispersão calculadas sobre os 2.930 imóveis da base, foi possível aprofundar a resposta à problematização inicial e refinar os critérios objetivos de precificação propostos na Sprint 1.

6.1 Recomendações Práticas para a Imobiliária

1. **Precificar pela faixa interquartil:** adotar Q1, mediana e Q3 como valores mínimo, típico e máximo esperados para um imóvel padrão, ajustando dentro dessa faixa conforme os atributos do imóvel.
2. **Protocolo para imóveis atípicos:** encaminhar para avaliação dedicada todo imóvel com lote superior a 17.727,75 ft², pois esses casos fogem ao comportamento estatístico da carteira.
3. **Usar a área do lote apenas dentro do segmento padrão:** a área é um bom parâmetro para os 2.803 lotes padrão, mas não deve ser extrapolada para os lotes discrepantes.
4. **Precificação regionalizada:** A avaliação dos imóveis não deve utilizar uma única tabela global para a cidade inteira. Os parâmetros de preço mínimo (Q1), típico (mediana) e máximo (Q3) devem ser segmentados por bairro, respeitando os patamares de valorização e a dispersão específica de cada localização identificada no boxplot comparativo.

6.2 Limitações da Sprint 2 e Próximos Passos

Como evidenciado na análise das medidas de dispersão e no boxplot comparativo por bairro, a área do lote (*Lot Area*) e a localização, isoladamente, não explicam toda a variabilidade observada no Preço de Venda (*SalePrice*). Permanece uma variabilidade residual substancial na carteira que reflete a influência de outros atributos físicos e qualitativos dos imóveis.

Para as próximas Sprints, recomenda-se:

- **Ampliar o escopo de variáveis analisadas:** Expandir a análise descritiva e exploratória para as demais variáveis quantitativas e qualitativas disponíveis na base de dados, identificando quais atributos possuem maior poder explicativo sobre o preço.
- **Incorporar atributos físicos e de qualidade:** Incluir no estudo variáveis determinantes para a avaliação imobiliária, tais como a área construída acima do solo (*Gr Liv Area*), o ano de construção (*Year Built*) e os índices de qualidade geral e estado de conservação (*Overall Qual* e *Overall Cond*).
- **Evoluir para Modelagem Multivariada:** Avançar da análise exploratória para um modelo de **Regressão Linear Múltipla**, permitindo isolar o efeito marginal de cada característica do imóvel e mensurar o seu impacto específico no valor final de venda.

7. Referências Bibliográficas

MONTEIRO, Alexandre et al. 2.Tabelas e Gráficos. Campinas: PUC-Campinas, 2026. Material de apoio para a disciplina Estatística e Análise de Dados, disponibilizado no ambiente virtual Canvas. Disponível em: <https://puc-campinas.instructure.com>. Acesso em: 11 ago. 2026.

MONTEIRO, Alexandre et al. 3-Python - Gráficos e Medidas. Campinas: PUC-Campinas, 2026. Material de apoio para a disciplina Estatística e Análise de Dados, disponibilizado no ambiente virtual Canvas. Disponível em: <https://puc-campinas.instructure.com>.